

朴素贝叶斯玩转垃圾短信分类预测- 实验指导书

一、实验目标

本实验主要利用朴素贝叶斯（Naive Bayes）分类模型进行垃圾短信分类预测（来源于 UCI 机器学习库的数据集），通过对垃圾短信文本数据的处理，采用三种基于不同先验概率分布的朴素贝叶斯分类模型进行预测，通过比较模型评价指标，进而获得较为最优的朴素贝叶斯分类模型。

本实验涉及到的是朴素贝叶斯分类模型，由于数据的先验概率分布未知，我们采用三种基于不同先验分布（高斯（Gauss）分布、伯努利（Bernoulli）分布、多项式（Multinomial）分布）的朴素贝叶斯模型来进行分类预测，进而得到较优的模型。本实验中朴素贝叶斯分类模型可直接调用 scikit-learn 库中的模型，具体实验目标如下：

- 1) 掌握对单词文本数据的编码转化处理方法；
- 2) 了解朴素贝叶斯模型的基本原理；
- 3) 掌握 Scikit-learn 库中的朴素贝叶斯分类模型 API 的调用；
- 4) 掌握分类模型的评价指标（准确率、精确率、召回率、 F_1 值和 AUC）的计算。

二、实验说明

2.1 实验难度与时长

实验难度	☆☆	建议时长	60 分钟
------	----	------	-------

2.2 前置知识

本实验主要使用的知识点包括：

序号	知识点	能力要求
----	-----	------

1	朴素贝叶斯分类模型	了解朴素贝叶斯分类的基本原理
2	分类模型的评价指标	掌握分类模型的评价指标：准确率、精确率、召回率、 F_1 值和 AUC
3	Scikit-learn 库中分类模型 API 的调用	掌握 Scikit-learn 中的 3 种朴素贝叶斯分类模型 API 的调用以及模型常用参数的调整

针对上面提到的分类模型，给出相应模型的基本公式、原理以及模型求解（包括学习三要素：模型，策略和算法），并给出分类模型的评价指标。

1) 模型的基本公式、原理及模型的求解

A. 朴素贝叶斯模型

朴素贝叶斯法是基于贝叶斯公式与特征相互独立假设的分类方法（本实验考虑二分类），它之所以叫“朴素”，是由于假设数据所有特征之间相互独立。贝叶斯分类模型为（ X 为模型所选取的特征， n 个）

$$P(y_i|X), \quad i = 1, 2$$

就是数据样本属于每个类别 $y_i \in \{0, 1\}$ 的条件概率（后验概率）， $P(y_1|X) + P(y_2|X) = 1$ 。

本实验中：垃圾短信（spam）的类别为 1，正常短信（ham）的类别为 0。

B. 策略（目标函数的选取）：

我们的分类目标就是最小化所有数据样本的总体分类错误率，若单个数据样本所产生的分类错误率最小化，则样本总体的分类错误率也将被最小化。

单个数据样本的分类错误率为：

$$R(y_i|X) = \sum_{j=1}^2 \text{loss}(y_i, y_j) * P(y_j|X)$$

贝叶斯分类模型采用 0-1 损失函数这种最原始的损失函数：

$$\text{loss}(y_i, y_j) = \begin{cases} 0, & i = j \\ 1, & \text{其他} \end{cases}$$

即当数据样本预测类别 y_j 与已知类别 y_i 相等，损失为 0，否则为 1。

此时，分类错误率为：

$$R(y_i|X) = 1 - P(y_i|X), \quad y_i \in \{0,1\}$$

因此我们的目标函数为

$$\min_{y_i \in \{0,1\}} R(y_i|X) = \max_{y_i \in \{0,1\}} P(y_i|X)$$

即对于待分类的样本，求在出现此样本的条件下各个类别的后验概率，然后找出最大的后验概率对应的类别。

C. 算法（目标函数求解）

由于目标函数为最大化后验概率，而后验概率难于求解，庆幸的是有贝叶斯公式可将后验概率转化为先验概率。贝叶斯公式为：

$$P(y|X) = \frac{P(X, y)}{P(X)} = \frac{P(y) P(X|y)}{P(X)}$$

- a) 分母 $P(X)$ 与类别无关，因此对所有的类都是相同的，由于分类的规则是将样本归到后验概率最大的那个类别，不需要计算准确的概率值，只需要知道属于哪个类别的概率最大即可，这样可以忽略掉分母 $P(X)$ ； $\max_y P(y|X) \Leftrightarrow \max_y P(y) P(X|y)$
- b) 根据大数定律，类别的概率 $P(y)$ 可以用类别出现的频率来估计；
- c) 根据朴素贝叶斯的样本特征相互独立的假设，有

$$P(X|y) = \prod_i P(x_i|y)$$

此时可根据极大似然估计来计算

- 特征为离散型：计算出的 $P(x_i|y)$ 为相应样本出现的频率
- 特征为连续型：需假定数据样本服从某一概率分布（高斯分布、伯努利分布...），来计算连续型的特征概率（概率密度函数）

根据上述的问题转化，求解目标函数只需按照 b)和 c) 来计算。

2) 分类模型的评价指标

二分类的效果评价指标有很多，常见的包括准确率（accuracy）、精确率（precision）和召回率（recall）以及综合评价指标（ F_1 值），另外 ROC 曲线（Receiver Operating Characteristic）和 AUC（Area Under Curve，ROC 曲线下的面积）可以用来衡量分类模型的预测能力，AUC 值越大，模型预测越优。

对于样本的分类可将样本根据其真实类别和预测类别进行组合划分为真正例（true positives, TP），真反例（true negatives, TN），假正例（false positives, FP），假反例（false negatives, FN），分类结果构成的混淆矩阵（Confusion matrix）表，如下：

真实情况	预测结果	
	正例	反例
正例	TP	FN
反例	FP	TN

本实验垃圾短信分类中，垃圾短信（spam）的类别为 1（正例），正常短信（ham）的类别为 0（反例），真正例（TP）是指分类器将一个垃圾短信分为 spam 类，真反例是指分类器将一个正常短信分辨为 ham 类，假正例是指分类器将一个正常短信分辨为 spam 类，假反例是指分类器将一个垃圾短信分辨为 ham 类。

根据上表，定义分类的评价指标如下：

A. 准确率（accuracy）：正确预测的正反例数/总数

$$\text{Accuracy} = \frac{TP + TN}{TP + FN + FP + TN}$$

B. 精确率（precision），也称查准率，正确预测的正例数/预测正例总数

$$P = \frac{TP}{TP + FP}$$

C. 召回率（recall），也称查全率、真正例率，正确预测的正例数/实际正例总数


$$R = \frac{TP}{TP + FN}$$

D. F_1 值（ F_1 score），是精确率与召回率的调和平均值

$$\frac{1}{F_1} = \frac{1}{2} \left(\frac{1}{P} + \frac{1}{R} \right)$$

E. ROC 曲线和 AUC 值

ROC 曲线以召回率为纵轴，以假正例率为横轴，ROC 曲线下的面积为 AUC 值。



3) TF-IDF 算法（单词文本处理时使用）

由于本实验针对垃圾短信进行分类预测，涉及到单词文本的处理，使用 TF-IDF 算法来度量每个单词的权重。

TF-IDF 的主要思想是：如果某个词在一篇文档中出现的频率 TF 高，并且在其他文档中很少出现（IDF 高），则认为此词或者短语具有很好的类别区分能力，适合用来分类。TF-IDF 实际上是：TF * IDF，其中 TF 词频（Term Frequency）表示某词在文档中出现的频率，即

$$TF = \frac{\text{某词在文档中出现的次数}}{\text{该文档的总次数}}$$

逆向文件频率（inverse document frequency, IDF）是某一特定词的 IDF，它是一个词语普遍重要性的度量。可以由总文档数目除以包含该词之文档的数目，再对得到的商取对数，即

$$IDF = \log \left(\frac{\text{总文档数目}}{\text{包含该词之文档的数目}} \right)$$

本实验中我们计算每个词的 TF-IDF 权重，以 TF-IDF 值作为模型的特征值，是否为垃圾短信为分类类型值。

4) TF-IDF 计算举例说明

假设现在有一篇文章，文章中包含 10000 个词组，其中，“安徽”出现 100 次，“的”出现 500 次，那么可以计算得到这几个词的 TF(词频)值：

$$TF(\text{安徽}) = \frac{100}{10000} = 0.01$$

$$TF(\text{的}) = \frac{500}{10000} = 0.05$$

现在数据集中有 1000 篇文章，其中包含“安徽”的有 99 篇，包含“的”的有 899 篇，则它们的 IDF 值计算为：

$$IDF(\text{安徽}) = \log\left(\frac{1000}{99 + 1}\right) = 1.000$$

$$IDF(\text{的}) = \log\left(\frac{1000}{899 + 1}\right) = 0.046$$

则“安徽”和“的”的 TFIDF 值分别为：

$$TFIDF(\text{安徽}) = TF(\text{安徽}) * IDF(\text{安徽}) = 0.01 * 1 = 0.01$$

$$TFIDF(\text{的}) = TF(\text{的}) * IDF(\text{的}) = 0.05 * 0.046 = 0.0023$$

很明显， $TFIDF(\text{安徽}) > TFIDF(\text{的})$ ，“的”相较于“安徽”不具有很好的类别区分能力。

2.3 实验环境

本实验的实验环境如下：

序号	分类	具体描述
1	系统环境	Window10
2	软件环境	Python3.7.3
3	依赖类库	Scikit-learn0.21.3; NumPy 1.17.3; Pandas 0.25.3; Matplotlib 3.1.1 等

2.4 数据集说明

2.4.1 数据说明

本实验的数据集为关于垃圾短信分类的数据集，来源于 UCI 机器学习数据库中的数据 (<http://archive.ics.uci.edu/ml/machine-learning-databases/00228/>)，数据集包括短信分类标识 (spam 和 ham)、短信文本内容，共有 5572 条短信样本，其中为 spam 的短信样本 (垃圾短信) 有 747 条，为 ham 的短信样本 (正常短信) 有 4825 条。

2.4.2 数据特征

选取的垃圾短信分类数据共包含 2 个的特征，第一列为短信分类标识，第二列为短信文本内容，无特征名称，以水平制表符（\t）进行分隔，如下：

特征序号	特征名称	英文说明	特征解释	数据类型	特征说明
1	--		垃圾短信分类 (spam/ham)	string	目标变量
2	--		短信文本	string	

2.4.3 数据样例

```
1 ham Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...
2 ham Ok lar... Joking wif u oni...
3 spam Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry qi
4 ham U dun say so early hor... U c already then say...
5 ham Nah I don't think he goes to usf, he lives around here though
6 spam FreeMsg Hey there darling it's been 3 week's now and no word back! I'd like some fun you up for it still?
7 ham Even my brother is not like to speak with me. They treat me like aids patent.
8 ham As per your request 'Melle Melle (Oru Minnaminunginte Nuringu Vettam)' has been set as your callertune for
9 spam WINNER!! As a valued network customer you have been selected to receivea £900 prize reward! To clc
10 spam Had your mobile 11 months or more? U R entitled to Update to the latest colour mobiles with camera for
```

例如第 1 条数据样本（为正常短信）如下：

```
1 ham Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...
```

2.5 代码框架说明

本实验提供的代码框架（均写同一个文件中）如下：

 naive_bayes_classification_Spam_SMS_data.py

其中，naive_bayes_classification_Spam_SMS_data.py 文件的作用是调用 SMSSpamCollection 数据集进行基于不同分布的朴素贝叶斯分类训练、预测，并给出对应模型的评价指标，该文件中包含 3 个函数：

函数分类	序号	函数名	函数具体功能
数据处理	1	data_preprocess	数据读取、数据集划分及单词文本处理及标签数值化处理

模型训练、 测试及评价	2	naive_bayes_with_diff_distri bution	构建基于不同分布的朴素贝叶斯分类 模型函数，进行训练、预测与评价
----------------	---	--	-------------------------------------

2.6 术语解释

本实验涉及到的专业术语包含：

- 1) 模型数据预处理
- 2) 模型训练
- 3) 模型拟合
- 4) 模型评价

三、 实验内容

3.1 步骤 1：实验环境与实验效果预览


本次实验的输出效果如下图所示：

 naive_bayes_classification_Spam_SMS_data.py

 ROC_AUC_with_model_BernoulliNB.png

 ROC_AUC_with_model_GaussianNB.png

 ROC_AUC_with_model_MultinomialNB.png



3.2 步骤 2：导入模型依赖的工具包

3.2.1 实现要求

借助 python 已有的工具包，导入实验模型依赖库及实验环境要求库。

```
import pandas as pd
import warnings

from sklearn.feature_extraction.text import TfidfVectorizer # 文本型数据处理
from sklearn.preprocessing import LabelEncoder # 字符串型数据编码
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB, BernoulliNB, MultinomialNB
from sklearn.metrics import roc_curve, auc
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
```

3.2.2 实现过程

```
from matplotlib import rcParams
import matplotlib
matplotlib.use("Agg") # 输出时不显示绘图
import matplotlib.pyplot as plt # matplotlib.use('agg')必须在本句执行前运行

rcParams['font.family'] = 'simhei' # 可以让图像中显示中文（黑体），无需引用
rcParams['axes.unicode_minus'] = False # 解决负数坐标显示问题
warnings.filterwarnings('ignore')
```

- 1) 输出时不显示绘制的图像，要求：

matplotlib.use('agg') 必须在 import matplotlib.pyplot as plt 执行前运行

- 2) 在图像中中文显示以及负数坐标显示，要求：

rcParams['font.family'] = 'simhei'

rcParams['axes.unicode_minus'] = False

3.2.3 结果评价

完成该步骤后，我们就实现了实验环境的设置和解决了在图像中中文显示以及负数坐标显示问题。

3.3 步骤 3： 实现数据读取、字符型数据数值化及数据集划分

3.3.1 实现要求

上一步我们完成了实验环境的设置。

接下来，我们要实现数据读取、数据集的划分、单词文本处理及数据集标签数值化功能，主要应用 pandas 的 read_csv、model_selection 中 train_test_split、feature_extraction.text 中的 TfidfVectorizer 和 preprocessing 中 LabelEncoder 来完成它。

3.3.2 实现过程

在 data_preprocess 函数中，先从文件中读取数据集 SMSSpamCollection，了解数据基本统计信息，然后根据 train_size 对数据集进行划分，得到训练集和测试集，但数据集为单词文本数据，需利用 TfidfVectorizer 来处理训练集和测试集中单词文本，获得单词 TF-IDF 值，构成矩阵，再利用 LabelEncoder 来处理训练集和测试集中的字符串型数据，获得 0、1 分类标签，代码如下：

```
# 步骤1 todo: 数据读取、数据集划分及单词文本处理及标签数值化处理
def data_preprocess(train_size=0.67):
    # 步骤1.1 todo: 读取数据并统计数据类别信息
    df = pd.read_csv('./data/SMSSpamCollection', delimiter='\t', header=None) # 利用pandas直接读取已有数据，数据以tab分割
    # print(df.describe()) # 了解数据的基本信息
    print('为spam短信数量: ', df[df[0] == 'spam'][0].count())
    print('为ham短信数量: ', df[df[0] == 'ham'][0].count())

    # 步骤1.2 todo: 先对整体数据按照train_size进行划分，得到训练集和测试集，random_state确保结果的一致性
    X_train_raw, X_test_raw, y_train_raw, y_test_raw = train_test_split(df[1], df[0], train_size=train_size,
                                                                    random_state=0)

    # 步骤1.3 todo: 对数据集中单词文本进行处理
    # 由于数据集为单词文本数据，构建TfidfVectorizer来计算每个单词的TF-IDF权重
    tfidf_vectorizer = TfidfVectorizer()
    X_train = tfidf_vectorizer.fit_transform(X_train_raw)
    X_test = tfidf_vectorizer.transform(X_test_raw)
    X_train = X_train.toarray() # 将数据矩阵转化为数组
    X_test = X_test.toarray()

    # 步骤1.4 todo: 目标变量中为字符串型数据，使用LabelEncoder处理 (spam=1, ham=0)
    le = LabelEncoder() # 对定型特征值化
    y_train = le.fit_transform(y_train_raw)
    y_test = le.transform(y_test_raw)
    return X_train, y_train, X_test, y_test
```

3.3.3 结果评价

完成该步骤后，我们就实现了数据读取、数据集的划分、单词文本处理及数据集标签数值化功能函数，接下来，我们可以在程序入口处，进行 `data_preprocess` 函数调用，获得训练集和测试集，在控制台可以查看分类数据情况。

```
if __name__ == '__main__':  
    # 步骤1 todo: 读取数据集, 并给出训练集和测试集  
    train_size = input('请输入训练集和测试集的划分比例(默认训练集比例0.67): ')  
    if train_size == '':  
        X_train, y_train, X_test, y_test = data_preprocess()  
    else:  
        train_size = float(train_size)  
        X_train, y_train, X_test, y_test = data_preprocess(train_size)
```

3.4 步骤 4： 实现基于不同的分布的朴素贝叶斯分类模型函数，进行训练、预测与评价

3.4.1 实现要求

上一步我们完成了数据读取、数据集的划分、单词文本处理及数据集标签数值化功能。

接下来，我们要实现基于不同的分布的朴素贝叶斯分类模型函数，进行训练、预测与评价的功能，主要应用 `sklearn` 库中 `GaussianNB`, `BernoulliNB`, `MultinomialNB` 来完成它。

3.4.2 实现过程

在 `naive_bayes_with_diff_distribution` 函数中，先调用选择的分类模型进行训练与测试，接着计算模型测试集的分类评价指标：准确率 `accuracy`、精确率 `precision`、召回率 `recall` 和综合评价指标 F_1 值，再绘制 ROC 曲线并保存 ROC 曲线图像，核心代码如下：

```
# 步骤2 todo: 进行朴素贝叶斯分类模型训练与测试、评价
# 由于选取的不同分布的朴素贝叶斯分类器，写成函数形式，便于引用
def naive_bayes_with_diff_distribution(model, model_name, X_train, y_train, X_test, y_test):
    # 步骤2.1 todo: 调用不同分布的朴素贝叶斯分类实例，进行训练测试
    NB_model = model
    NB_model.fit(X_train, y_train)
    y_test_predict = NB_model.predict(X_test)

    # 步骤2.2 todo: 计算分类评价指标：测试集的准确率accuracy、精确率precision、召回率recall和综合评价指标F1得分
    # 精确率是指分类器预测出的垃圾短信中真的是垃圾短信的比例
    # 召回率是所有真的垃圾短信被分类器正确找出来的比例
    # F1 值是精确率和召回率的调和均值
    acc_test = accuracy_score(y_test, y_test_predict) # 和模型自带的score一致
    precision_test = precision_score(y_test, y_test_predict)
    recall_test = recall_score(y_test, y_test_predict)
    f1score_test = f1_score(y_test, y_test_predict)
    print('%s 在测试集上的准确率为: %.4f' % (model_name, acc_test))
    print('%s 在测试集上的精确率为: %.4f' % (model_name, precision_test))
    print('%s 在测试集上的召回率为: %.4f' % (model_name, recall_test))
    print('%s 在测试集上的F1得分为: %.4f' % (model_name, f1score_test))

    # 步骤2.3 todo: 绘制ROC曲线，计算auc，度量分类模型的预测能力
    # ROC曲线以召回率为纵轴，以假正例率为横轴，ROC曲线下的面积为AUC值
    y_test_predict_proba = NB_model.predict_proba(X_test)
    false_positive_rate, recall, thresholds = roc_curve(y_test, y_test_predict_proba[:, 1])
    roc_auc = auc(false_positive_rate, recall) # 计算auc的值
    plt.figure()
    plt.title('%s 模型的 ROC-AUC 图' % model_name)
    plt.plot(false_positive_rate, recall, 'r', label='AUC = %.3f' % roc_auc)
    plt.legend(loc='best')
    plt.plot([0, 1], [0, 1], 'k--')
    plt.xlim([0.0, 1.0])
    plt.ylim([0.0, 1.0])
    plt.ylabel('真正例率(召回率)')
    plt.xlabel('假正例率')
    plt.savefig('ROC_AUC_with_model_{}.png'.format(model_name))
```

3.4.3 结果评价

完成该步骤后，我们就实现了实现基于不同的分布的朴素贝叶斯分类模型函数，进行训练、预测与评价的功能，接下来，我们可以在程序入口处，输入不同分布的朴素贝叶斯模型（'GaussianNB', 'BernoulliNB', 'MultinomialNB'），调用 naive_bayes_with_diff_distribution 函数调用，在文件目录下查看不同分布的朴素贝叶斯的 ROC_AUC 图，在控制台中查看分类模型评价指标结果。

```
# 步骤2 todo: 进行朴素贝叶斯分类模型训练与测试、评价
while True:
    model_name = input('请输入朴素贝叶斯模型(GaussianNB, BernoulliNB, MultinomialNB任选一个,输入q退出):')
    if model_name == 'q':
        break
    else:
        if str(model_name) == 'GaussianNB':
            model = GaussianNB()
            naive_bayes_with_diff_distribution(model, model_name, X_train, y_train, X_test, y_test)

        if str(model_name) == 'BernoulliNB':
            model = BernoulliNB()
            naive_bayes_with_diff_distribution(model, model_name, X_train, y_train, X_test, y_test)

        if str(model_name) == 'MultinomialNB':
            model = MultinomialNB()
            naive_bayes_with_diff_distribution(model, model_name, X_train, y_train, X_test, y_test)

print('模型训练测试结束!')
```

四、实验最终效果与评价

4.1 输入与结果

4.1.1 输入主要包括以下

1) 数据集 SMSSpamCollection, 例:



```
1 ham Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...
2 ham Ok lar... Joking wif u oni...
3 spam Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry qi
4 ham U dun say so early hor... U c already then say...
5 ham Nah I don't think he goes to usf, he lives around here though
6 spam FreeMsg Hey there darling it's been 3 week's now and no word back! I'd like some fun you up for it still?
7 ham Even my brother is not like to speak with me. They treat me like aids patent.
8 ham As per your request 'Melle Melle (Oru Minnaminunginte Nurunгу Vettam)' has been set as your callertune for
9 spam WINNER!! As a valued network customer you have been selected to receive a £900 prize reward! To cl
10 spam Had your mobile 11 months or more? U R entitled to Update to the latest colour mobiles with camera for
```

2) 选择的算法模型 (GaussianNB), 例:

```
model = GaussianNB()
```

4.1.2 结果主要包括以下

1) ROC 曲线和 AUC 值结果, 例:



2) 模型评价指标，例：

```
请输入朴素贝叶斯模型(GaussianNB, BernoulliNB, MultinomialNB任选一个,输入q退出):> MultinomialNB
MultinomialNB 在测试集上的准确率为: 0.9603
MultinomialNB 在测试集上的精确率为: 1.0000
MultinomialNB 在测试集上的召回率为: 0.6983
MultinomialNB 在测试集上的F1得分为: 0.8224
请输入朴素贝叶斯模型(GaussianNB, BernoulliNB, MultinomialNB任选一个,输入q退出):> BernoulliNB
BernoulliNB 在测试集上的准确率为: 0.9777
BernoulliNB 在测试集上的精确率为: 1.0000
BernoulliNB 在测试集上的召回率为: 0.8306
BernoulliNB 在测试集上的F1得分为: 0.9074
请输入朴素贝叶斯模型(GaussianNB, BernoulliNB, MultinomialNB任选一个,输入q退出):> GaussianNB
GaussianNB 在测试集上的准确率为: 0.9010
GaussianNB 在测试集上的精确率为: 0.5789
GaussianNB 在测试集上的召回率为: 0.9091
GaussianNB 在测试集上的F1得分为: 0.7074
请输入朴素贝叶斯模型(GaussianNB, BernoulliNB, MultinomialNB任选一个,输入q退出):> q
```

4.2 评价结果说明

从实验模型评价指标中，可以看出：

- 1) 从测试的准确率来看，基于伯努利分布的朴素贝叶斯分类的数值最大，因此为所选模型中最优的；

注意：

- 1) 进行模型测试时，我们可以调整训练集和测试集的比例，以及选取朴素贝叶斯分类器不同参数（GaussianNB 无参数），进行模型参数优化；
- 2) 多项式分布的朴素贝叶斯分类只适用于处理特征离散情况；
- 3) 伯努利分布的朴素贝叶斯分类只适用于处理特征离散（0、1）情况。

五、参考资料与扩展阅读

- 1) 《机器学习》，周志华，清华大学出版社，2016 年
- 2) UCI 机器学习数据库中的数据： <http://archive.ics.uci.edu/ml/machine-learning-databases/00228/>
- 3) scikit-learn 库 API 的调用（scikit-learn-docs0.21.3）： <https://scikit-learn.org/>

六、附录

本实验的完整源码见平台的 FAQ 库。